Review finale des spécifications et de la roadmap — Astra

12 octobre 2026 — Relecture indépendante de SPECIFICATION.md v0.1 et ROADMAP.md, éclairée par l'audit d'écosystème et la review source Opus. Périmètre documentaire : aucun développement ni qualification des exécutables. P0 = correction avant implémentation concernée ; P1 = correction avant livraison du profil ; P2 = précision utile. Avis compact destiné à tenir sur quatre pages A4.

Verdict : favorable au lancement de PF-00, sous réserves ciblées ; pas encore un contrat scientifique entièrement exécutable. Les principaux défauts du document source sont corrigés : répétabilité absolue, séparation des vues, sélection imbriquée, unités explicites, absence de score global, frontières des dépôts et preuve MATLAB réelle. Le découpage Rust/Methods/DAG est cohérent. Les corrections suivantes ferment surtout des ambiguïtés capables de produire des résultats trompeurs malgré ces bons principes.

P0-1 — L'étanchéité doit porter sur les identités liées, pas seulement les lignes (§3-4, PF-00/04). Des `observation_ids` distincts et des hashes FIT/EVAL disjoints ne prouvent pas qu'un même objet, parent d'augmentation ou individu ne traverse pas train/test. Une agrégation exécutée avant la séparation pourrait aussi mélanger leurs acquisitions. Correction : définir avant toute agrégation les composantes d'identités qui doivent rester indivisibles, vérifier leurs intersections entre partitions puis à chaque niveau de CV, et refuser un plan incompatible avec l'objectif déclaré. Les facteurs croisés nécessitent une règle explicite ; tenir un site à l'écart n'exclut pas automatiquement les individus également mesurés ailleurs. Fixture exigée : mêmes objets sous identifiants d'acquisition différents dans développement et test, avec refus avant tout FIT.

P1-2 — Plan de permutation encore insuffisamment contractuel (§5.5/5.8, §6). « Sample/groupe » ne définit ni une hypothèse nulle ni l'échangeabilité. Un lot dont Y varie interdit généralement de permuter librement ses samples avec ceux des autres lots ; déplacer des blocs de tailles différentes n'est pas un simple échange de labels. Correction : chaque test expose effet testé, unité, restrictions, modèle réduit éventuel, hypothèses, nombre de permutations distinctes et résolution atteignable. Refuser les schémas non qualifiés plutôt que choisir automatiquement une permutation. Le MVP, qui propose déjà des associations métadonnées–Y, doit appliquer cette règle avant PF-06. PERMDISP ne valide pas à lui seul une PERMANOVA. La documentation vegan sur les permutations et effets aléatoires confirme cette distinction.

P1-3 — Cohérence locale : ne pas comparer directement les valeurs individuelles (§5.5). La formule proposée est admissible comme contraste descriptif, mais son niveau nul conditionnel dépend de y_i. Sous échange uniforme des voisins, $E[L_i \mid y_i] = 1/2 - n(y_i-\bar{y})^2/[2(n-1)s_y^2]$: une cible extrême reçoit donc un niveau attendu inférieur même sans relation X–Y. Correction : conserver le contraste global préspécifié ; pour les constats locaux, afficher distance spectrale et différences de référence, et comparer chaque contraste à son nul conditionnel autorisé. En catégoriel, employer les proportions parmi les voisins réellement admissibles, sans auto-inclusion. Aucun seuil commun de « contradiction » fondé uniquement sur L_i.

P1-4 — Censure et références partagées : transport sans politique de calcul (§3, §5.4–6). Une limite de détection n'est pas une concentration exacte. De même, un `reference_id` partagé entre plusieurs objets peut désigner une référence composite et ne doit pas fabriquer autant de valeurs indépendantes. Correction : définir avant PF-03 les cas admissibles pour sonde, cohérence et tests : valeur exacte, intervalle/censure, mesure composite, références multiples incompatibles. Sans protocole dédié, exclure explicitement les cibles censurées des calculs exigeant des valeurs ponctuelles, publier les exclus et borner l'interprétation à cette population. Ne pas substituer implicitement LOD/2 ou une borne.

P1-5 — Les seuils arrivent après leur première livraison (PF-03 versus PF-09). Le MVP émet constats, classes et recommandations alors que calibration des règles/confiance est reportée à la RC. Correction : chaque lot livre son propre gate scientifique minimal, ses fixtures et le statut de ses règles. Avant calibration, confiance unknown ou observations exploratoires ; pas de high simplement lié à un grand effectif. Fixer les familles de tests, budgets de permutations et règles d'effectif avec le protocole, puis élargir leur validation en PF-09. Les recommandations de split doivent préciser domaine visé, groupes disponibles et limites d'identifiabilité.

P1-6 — Le spike PCA ne ferme pas le risque DAG/WASM (PF-00, §8). PCA démontre le transport d'une matrice, pas la sélection imbriquée, la persistance d'états de modèles ni la coordination entre `MethodsProvider` et `ValidationProvider`. Correction : ajouter à PF-00 une tranche minimale train/transform/predict avec deux folds groupés, exécution DAG réelle CPU/navigateur, états détenus par leur fournisseur, annulation et réponse tardive rejetée. Définir qui crée les folds, pilote les fits et possède les handles. Rendre explicites les profils où la sonde navigateur est indisponible, sans prétendre avoir qualifié toute l'architecture par le seul spike PCA.

P1-7 — La garantie ABI sur les pointeurs est trop forte (§7). Vérifier forme, longueur, alignement et overflow ne permet pas de prouver qu'un pointeur C arbitraire désigne une allocation encore valide. Correction : documenter les préconditions obligatoires de l'appelant, rendre les wrappers sûrs responsables de leur respect et fixer la propriété des données sur toute la durée d'un job. Inclure interdiction de mutation concurrente des buffers empruntés, invalidation des handles et stratégie après erreur/panic. La sécurité de `slice::from_raw_parts` exige notamment allocation valide, durée de vie et absence de mutation incompatible ; ces obligations ne disparaissent pas avec un champ longueur.

P2-8 — ICC : compléter le profil déjà prudent (§5.2). Nommer explicitement l'ICC unidirectionnel de mesure unique, distinguer sa valeur de la fiabilité d'une moyenne de répétitions, et publier l'estimateur ANOVA. Vérifier l'équilibre après application du masque, bande par bande. Distinguer variance totale nulle, composante estimée négative et plan déséquilibré non supporté. Ce dernier est `unsupported`, plutôt que `not_applicable` comme dans l'exemple actuel. Le report de REML reste raisonnable.

P2-9 — Stabilité et qualité produit (§5.7, §9). ARI sur les seuls points doublement assignés peut être excellent sur une petite fraction : l'exigence de fraction comparée est bonne, mais doit conditionner la confiance. Définir l'appariement des clusters pour leur « fréquence d'apparition ». Lors d'un Cancel par destruction du worker, préserver dans l'hôte les résultats terminés et leur provenance avant destruction ; sinon la promesse de rapport partiel est fragile. Conserver le résumé textuel visible et les tables accessibles comme gates du MVP.

P1-10 — Enveloppe plausible, engagement prématuré (roadmap §2–4). La somme 108–164 jours-personnes est correcte. Les 14–22 semaines à deux personnes supposent toutefois disponibilité des propriétaires Methods/IO/DAG/Core/R, installations multi-OS et licence MATLAB ; deux contributeurs ne rendent pas ces dépendances parallèles automatiquement. À J0, établir une matrice minimale OS/version/opération, intégrer les charges amont ou les identifier comme externes, puis réestimer avec réserve explicite. Conserver le gate MATLAB réel et une release MVP distincte si nécessaire. Aucun besoin de réécrire la roadmap : ces contrats et preuves suffisent à la rendre pilotable.